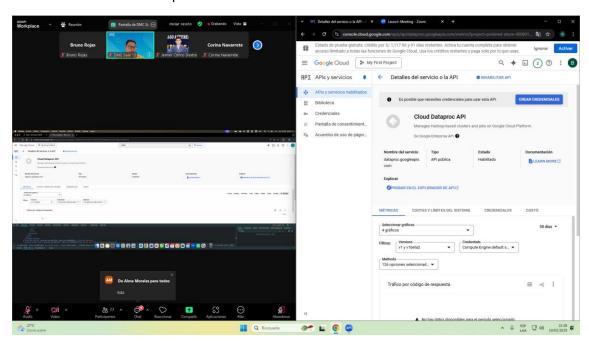
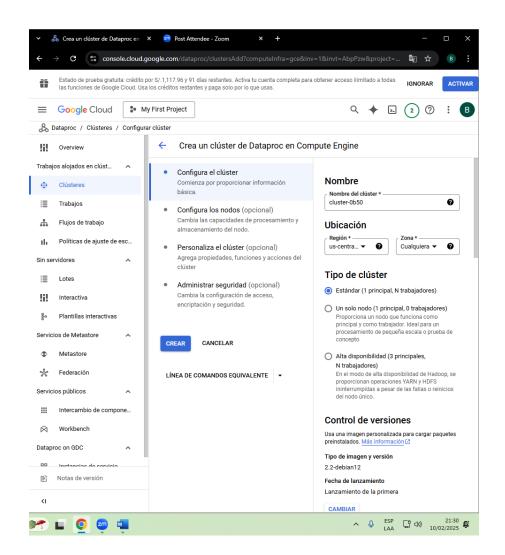
Trabajo Especialización Big Data

https://github.com/BrunoRojasB/curso-dmc-big-data-processing

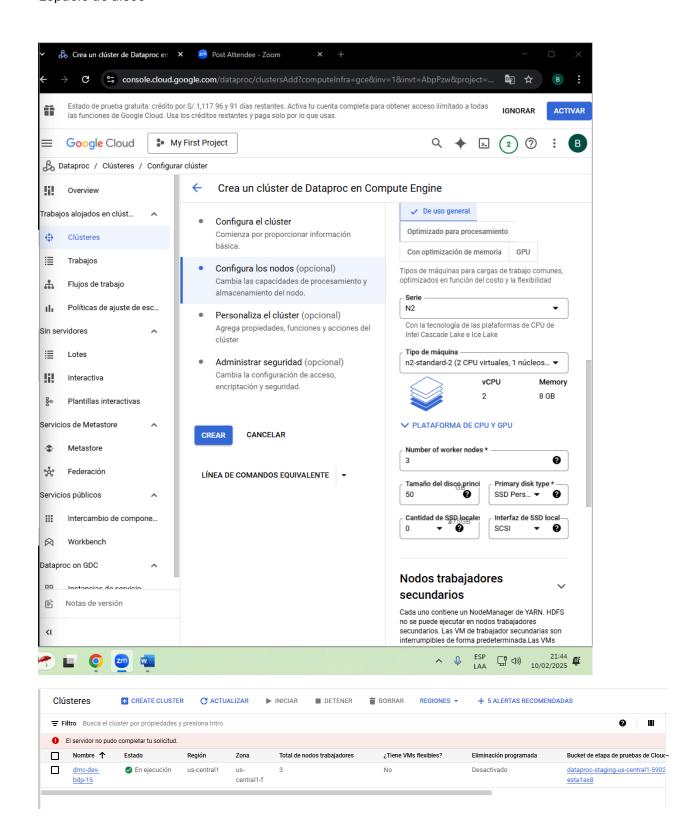
1.- HDFS

Creación de Clúster Dataproc

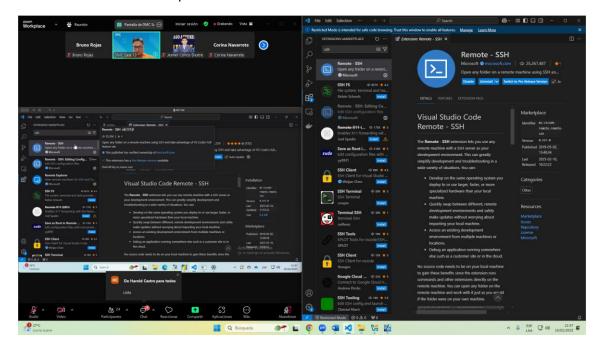




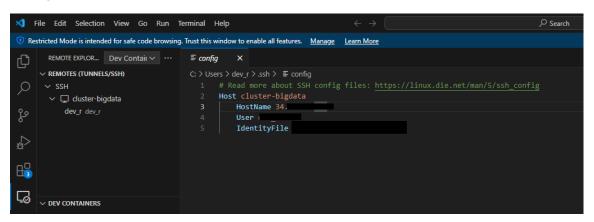
Configuración de Nodos Tipo de Máquina Número de nodos trabajadores Espacio de disco



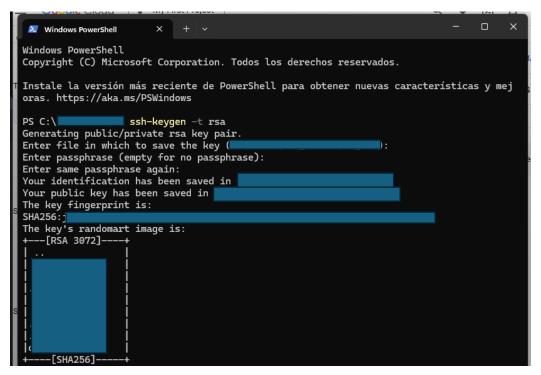
Instalación de Remote Explorer en Visual Studio Code



Configuración de Remote Explorer

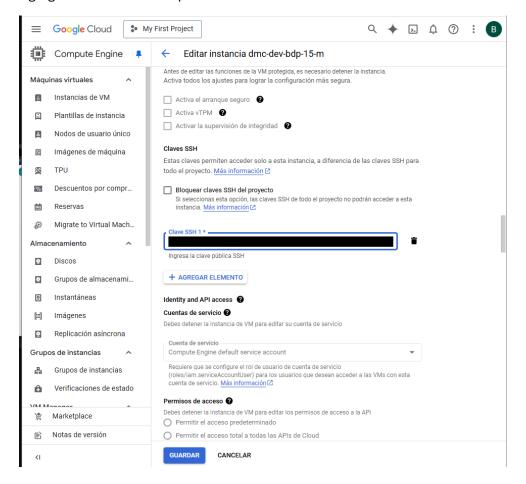


Generación de clave SSH.

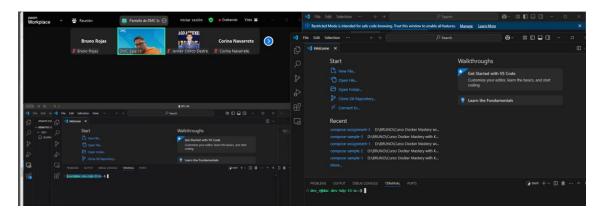


Mode	LastWriteTime 		Length 	Name
-a	10/02/2025	22:10	2610	id_rsa
-a	10/02/2025	22:10	576	id_rsa.pub
-a	2/12/2023	19:20	840	known_hosts
-a	2/12/2023	18:45	96	known_hosts.old

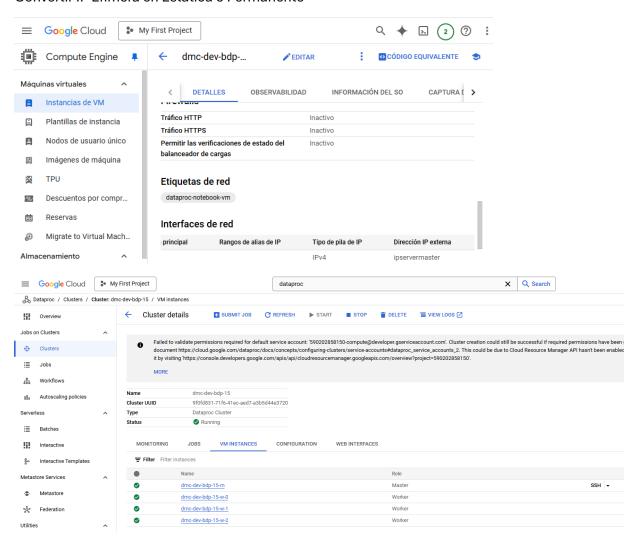
Agregar clave SSH a Dataproc



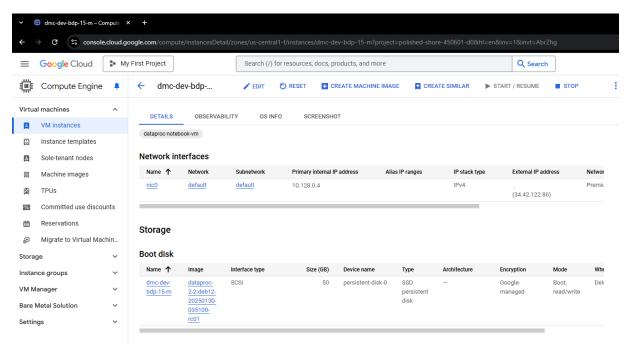
Nos conectamos al cluster desde Visual Studio Code con Remote Explorer



Convertir IP Efímera en Estática o Permanente

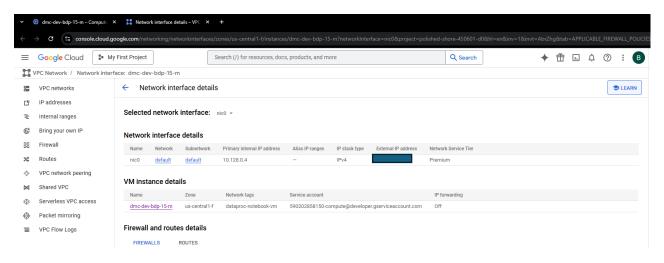


Entramos al master y bajamos hasta network interfaces

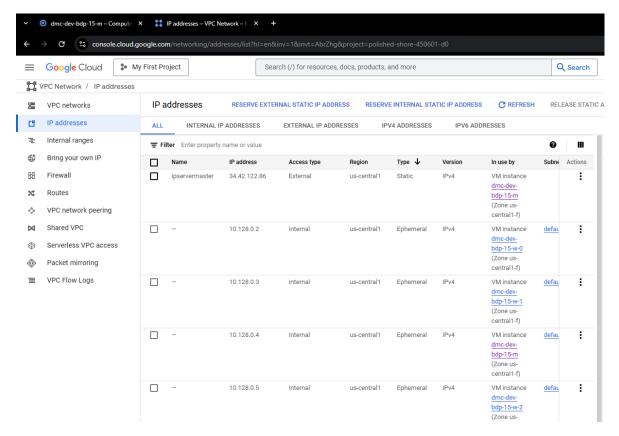


La ip que normalmente aparece como ephimeral o efímera

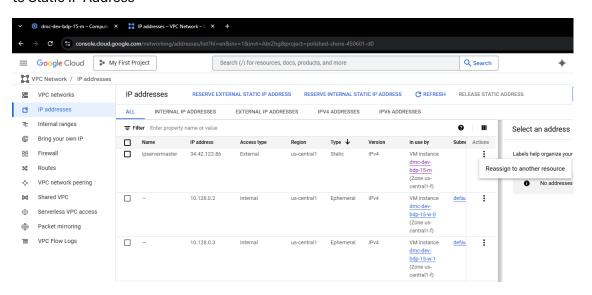
Click derecho sobre nic0 -> Abrir en una nueva ventana



Click IP addresses



Click en los tres puntitos de la IP que está usando nuestro servidor y dar click en Promote to Static IP Address



Debería aparecer promover a ip estática

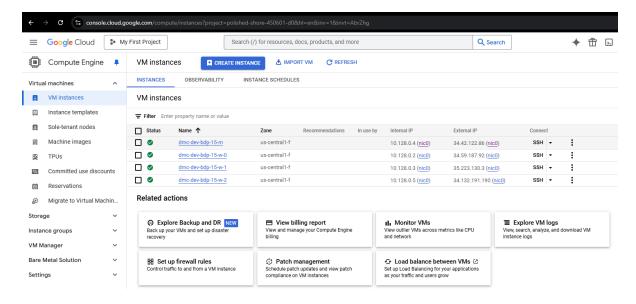


Le colocamos un nombre y descripción

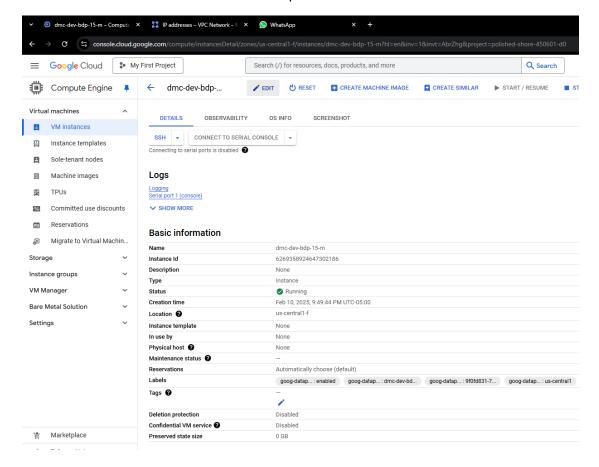


Luego la ip cambiaría de efímera a estática y es la que usaríamos siempre para conectarnos.

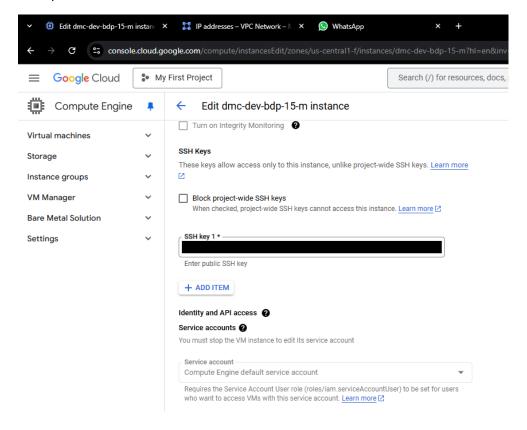
Para añadir una llave ssh



Entramos al servidor maestro dmc-dev-bdp-15-m



Damos click en edit. Bajamos hasta ssh keys. Y damos click en add item y se añade la llave pública.



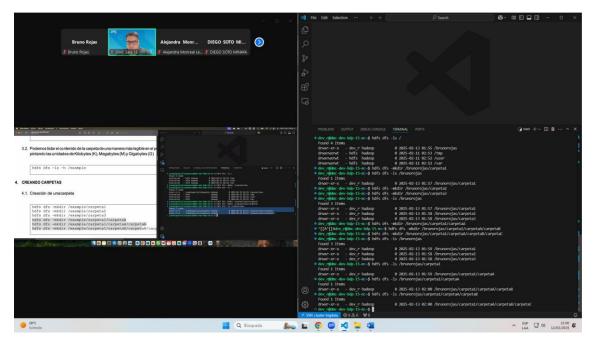
Comandos en HDFS

Listar carpetas en HDFS: hdfs dfs -ls /

Crear directorios en HDFS: hdfs dfs -mkdir /brunorojas

Crear una carpeta dentro de otra: hdfs dfs -mkdir /brunorojas/carpeta2

Listar el contenido de la carpeta: hdfs dfs -ls /brunorojas



Crear archivo vacío: hdfs dfs -touchz /brunorojas/archivovacio.txt

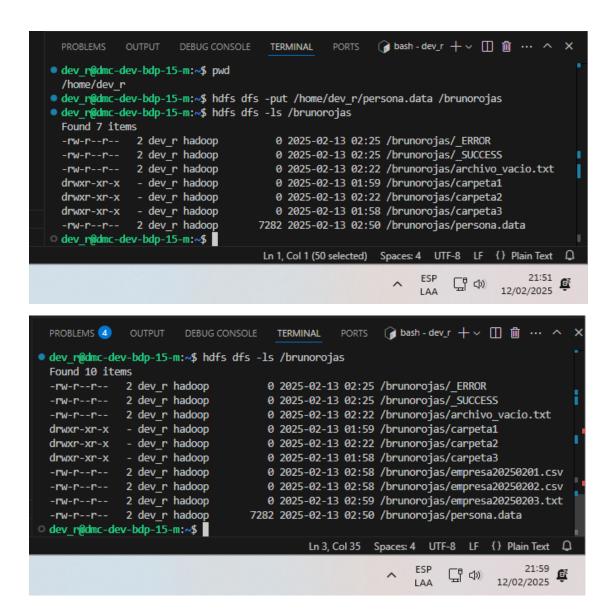
```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -touchz /brunorojas/archivo_vacio.txt
dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -ls /brunorojas
Found 4 items
-rw-r--r- 2 dev_r hadoop 0 2025-02-13 02:22 /brunorojas/archivo_vacio.txt
drwxr-xr-x - dev_r hadoop 0 2025-02-13 01:59 /brunorojas/carpeta1
drwxr-xr-x - dev_r hadoop 0 2025-02-13 02:22 /brunorojas/carpeta2
drwxr-xr-x - dev_r hadoop 0 2025-02-13 01:58 /brunorojas/carpeta3
dev_r@dmc-dev-bdp-15-m:~$
```

Creamos un archivo txt dentro del servidor para ir guardando nuestros comandos.

Para llevar un archivo de Linux a hdf se usa el comando put

hdfs dfs -put /home/dev_r/persona.data /brunorojas hdfs dfs -put /home/dev_r/empresa*.csv /brunorojas hdfs dfs -put /home/dev_r/empresa* /brunorojas



Usamos el comando cat para leer el contenido de un archivo.

hdfs dfs -cat /brunorojas/persona.data

Usamos el commando rm para eliminar un archivo. La f es para forzar el borrado.

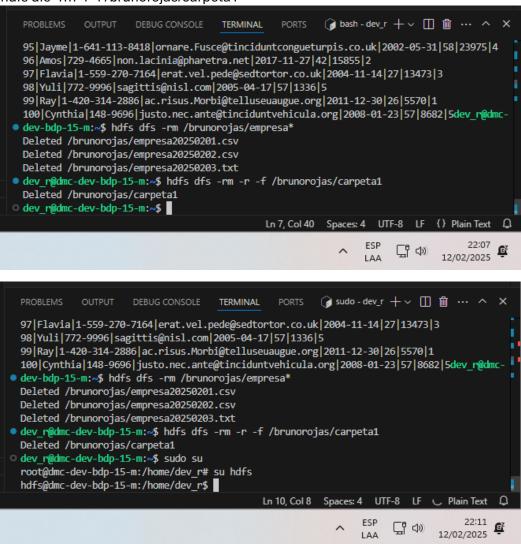
hdfs dfs -rm -f /brunorojas/persona.data

Se puede eliminar usando comodines también.

hdfs dfs -rm /brunorojas/empresa*

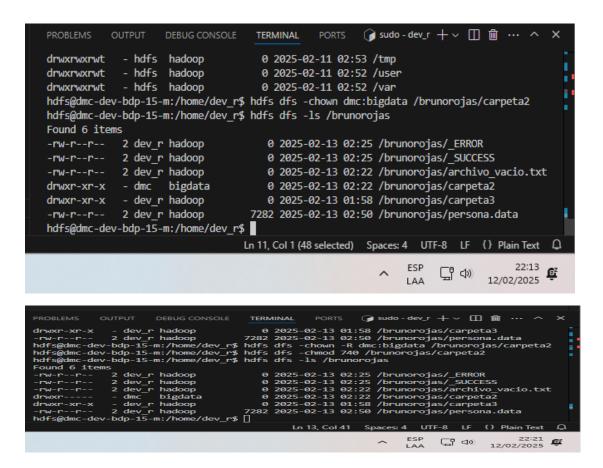
Si se quiere eliminar de forma recursiva es decir los archivos o carpetas dentro de una carpeta se usa -r

hdfs dfs -rm -r -f /brunorojas/carpeta1



Para poder realizar el cambio de permisos de ejecución, escritura y lectura así como del propietario de un archivo o carpeta se debe realizar con el superusuario.

Cambiamos a superusuario en Linux con : sudo su
Cambiamos a superusuario en hdfs con: su hdfs
Estructura del comando chown: chown usuario:grupo ruta
Cambiar de propietario a una carpeta
hdfs dfs -chown dmc:bigdata /brunorojas/carpeta2
Cambiar de propietario de forma recursiva
hdfs dfs -chown -R dmc:bigdata /brunorojas/carpeta2
hdfs dfs -chmod 740 /brunorojas/carpeta2
hdfs dfs -chmod -R 750 /brunorojas/carpeta2



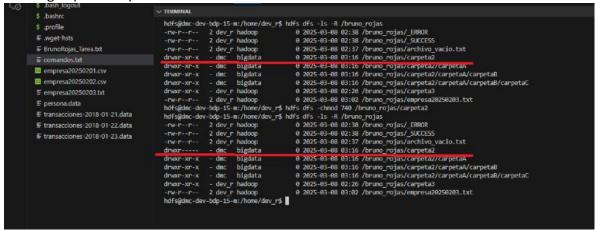
Para asignar permisos de lectura, escritura y ejecución se usa chmod.

hdfs dfs -chmod 740 /bruno_rojas/carpeta2

Permisos de lectura escritura y ejecución para DMC

Permisos de lectura para el grupo bigdata

Sin ningún permiso para otros usuarios



Permisos con ACL

Estructura del comando setfacl: hdfs dfs -setfacl -R -m user:nombreusuario:wwx /ruta hdfs dfs -setfacl -R -m user:leonor:rw- /bruno_rojas/archivo_vacio.txt hdfs dfs -setfacl -R -m group:ulimar:r-x /bruno_rojas/archivo_vacio.txt hdfs dfs -getfacl /bruno_rojas/archivo_vacio.txt

```
TERMINAL

√ TERMINAL

dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -ls /bruno_rojas
  Found 6 items
 -rw-r-r-- 2 dev_r hadoop 0 2025-03-08 02:38 /bruno_rojas/_ERROR
-rw-r-r-- 2 dev_r hadoop 0 2025-03-08 02:38 /bruno_rojas/_SUCCESS
-rw-r-r-- 2 dev_r hadoop 0 2025-03-08 02:37 /bruno_rojas/archivo_vacio.txt
drwxr---- - dmc bigdata 0 2025-03-08 03:16 /bruno_rojas/carpeta2
drwxr-xr-x - dev_r hadoop 0 2025-03-08 03:26 /bruno_rojas/carpeta3
-rw-r-r-- 2 dev_r hadoop 0 2025-03-08 03:02 /bruno_rojas/carpeta3
• dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -setfacl -R -m user:leonor:rwx /bruno_rojas/archivo_vacio.txt
• dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -setfacl -R -m group:ulima:r-x /bruno_rojas/archivo_vacio.txt
• dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -getfacl /bruno_rojas/archivo_vacio.txt
  # file: /bruno_rojas/archivo_vacio.txt
  # owner: dev_r
  # group: hadoop
  user::rw-
  user:leonor:rwx
  group::r-
  group:ulima:r-x
  mask::rwx
  other::r--
○ dev_r@dmc-dev-bdp-15-m:~$
```

Verificación de la integridad de los datos cksum /home/dev_r/persona.data hdfs dfs -cat /brunorojas/persona.data | cksum Listando pesos recursivamente hdfs dfs -du -s -h '/*' #14.2 K 28.4 K /brunorojas

Los que están en rojo son el doble porque hay dos réplicas.

```
• dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -put /home/dev_r/persona.data /bruno_rojas
dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -ls /bruno_rojas
 Found 7 items
 0 2025-03-08 03:02 /bruno_rojas/empresa20250203.txt

    dev_r@dmc-dev-bdp-15-m:~$ cksum /home/dev_r/persona.data

 229400302 7282 /home/dev_r/persona.data
● dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -cat /bruno_rojas/persona.data | cksum
 229400302 7282
dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -du -s -h '/*'
 7.1 K 14.2 K /bruno_rojas
 14.2 K 42.7 K /brunorojas
42.1 M 84.2 M /hadoop
       0 /tmp
 13.9 M 27.7 M /user
       Θ
               /var
○ dev_r@dmc-dev-bdp-15-m:~$
```

Cambiando el número de replicas a 3

hdfs dfs -setrep -w 3 -R /brunorojas

Ahora los pesos se multiplan por 3 porque hay tres réplicas.

```
    dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -setrep -w 3 -R /bruno roias

 setrep: `-R': No such file or directory
 Replication 3 set: /bruno_rojas/_ERROR
 Replication 3 set: /bruno_rojas/_SUCCESS
 Replication 3 set: /bruno_rojas/archivo_vacio.txt
 Replication 3 set: /bruno_rojas/empresa20250203.txt
 Replication 3 set: /bruno_rojas/persona.data
 Waiting for /bruno_rojas/_ERROR ... done
 Waiting for /bruno_rojas/_SUCCESS ... done
 Waiting for /bruno_rojas/archivo_vacio.txt ... done
 Waiting for /bruno_rojas/empresa20250203.txt ... done
 Waiting for /bruno_rojas/persona.data .... done
dev_r@dmc-dev-bdp-15-m:~$ hdfs dfs -du -s -h '/*'
 7.1 K <u>21.3 K</u> /bruno_rojas
 14.2 K 42.7 K /brunorojas
 42.1 M 84.2 M /hadoop
                 /tmp
         Θ
 13.9 M 27.7 M /user
                 /var
         Θ
 dev r@dmc-dev-bdp-15-m:~$
```