

4.-Lakehouse

Lakehouse con Databricks y Google Cloud Storage


Creación de estructura de carpetas




Creación de bucket en Google Cloud Storage para alimentar el Lakehouse




Leyendo datos de la capa landing de personas desde el bucket y armando el esquema del dataframe.




Guardando datos de la capa bronce en formato delta en el bucket de gcp. La tabla personas.



Validando en Google Cloud Storage que se creó la carpeta y la data.



Clonando archivos en databricks






Tabla empresas a la capa bronce







Tabla transacciones a la capa bronce






La Capa Silver




Limpieza y casteo de datos




```
#Importamos las librerías necesarias
from pyspark.sql import SparkSession
#from pyspark.sql.types import StructField, StructType,
StringType
from pyspark.sql.functions import regexp_replace,
date_format, current_date, add_months, when, col
from pyspark.sql.types import IntegerType, DoubleType
from datetime import datetime
from dateutil.relativedelta import relativedelta
```


Añadiendo columnas para enriquecer la data




Creación de partición en la tabla personas




Corroborando data en el bucket



Realizando casteo de datos en la tabla empresas



Validando creación de la tabla en el bucket



Añadiendo partición a la tabla transacciones y columnas nuevas


```
### Just now (10s)

df_c.write.mode("overwrite").partitionBy("ANIO","MES","DIA").format("delta").save(path_silver)

(6) Spark lobs
```

Guardando tabla en formato delta en el bucket

Validando data en el bucket



Poblando la capa Gold

10

10 Cadman

18665612701

orci.adipiscing.non@semperNam.ca

2001-05-19

io-process Python v

```
\vdots
              ✓ 09:06 PM (<1s)
         from pyspark.sql import SparkSession
         from pyspark.sql.types import *
         from pyspark.sql.functions import *
              ✓ 09:05 PM (<1s)
         spark = SparkSession.builder.getOrCreate()

✓ 09:05 PM (<1s)
</p>
         name_bucket = "dmc_dde_barb"
         path_lakehouse = f"gs://{name_bucket}/produccion/dmc"
         path_silver_personas = f"{path_lakehouse}/silver/personas/"
         path_silver_empresas = f"{path_lakehouse}/silver/empresas/"
         path_gold = f"{path_lakehouse}/gold/machine-learning/analisis-x-salario"
H
      ▶ ∨ ✓ 09:09 PM (4s)
         df_personas = spark.read.format("delta").load(path_silver_personas)
         display(df_personas)
         df_empresas = spark.read.format("delta").load(path_silver_empresas)
         display(df_empresas)
      ▶ (3) Spark Jobs
      ▶ ■ df_empresas: pyspark.sql.dataframe.DataFrame = [ID: integer, NOMBRE: string ... 1 more field]
      ▶ ■ df_personas: pyspark.sql.dataframe.DataFrame = [ID: integer, NOMBRE: string ... 11 more fields]
       Table v
             123 ID
                          ABC NOMBRE
                                             AB<sub>C</sub> TELEFONO
                                                                 ABC CORREO
                                                                                                                     FECHA_IN
                                             17456339145
                                                                                                                     2004-04-23
                       1
                          Carl
                                                                 arcu.Sed.et@ante.co.uk
                       2
                                                                                                                     2019-02-17
       2
                          Priscilla
                                             1552498
                                                                 Donec.egestas.Aliquam@volutpatnunc.edu
                       3
                                             12049568594
                                                                                                                     2002-08-01
                           Jocelyn
                       4
                                             17198629385
                                                                                                                     2018-11-06
       4
                          Aidan
                                                                 euismod.et.commodo@nibhlaciniaorci.edu
       5
                       5
                          Leandra
                                             8398044
                                                                 at@pretiumetrutrum.com
                                                                                                                     2002-10-10
                       6 Bert
                                             7974453
                                                                 a.felis.ullamcorper@arcu.org
                                                                                                                     2017-04-25
       6
                       7
                                             16801026792
                                                                                                                     2006-04-21
                          Mark
                                                                 Quisque.ac@placerat.ca
       8
                       8
                                             2142975
                                                                 eu.ultrices.sit@vitae.ca
       9
                       9
                                             9352277
                                                                                                                     2003-05-25
                          Hanae
                                                                 eu@Nunc.ca
```

Python 🗸

```
df_personas = spark.read.format("delta").load(path_silver_personas)
display(df_personas)

df_empresas = spark.read.format("delta").load(path_silver_empresas)
display(df_empresas)
```

- ▶ df_empresas: pyspark.sql.dataframe.DataFrame = [ID: integer, NOMBRE: string ... 1 more field]
- ▶ 🖃 df_personas: pyspark.sql.dataframe.DataFrame = [ID: integer, NOMBRE: string ... 11 more fields]

Table v +

	1 ² 3 ID	A ^B _C NOMBRE	ABC TELEFONO	A ^B C CORREO	
6	6	Bert	7974453	a.felis.ullamcorper@arcu.org	
7	7	Mark	16801026792	Quisque.ac@placerat.ca	
8	8	Jonah	2142975	eu.ultrices.sit@vitae.ca	
9	9	Hanae	9352277	eu@Nunc.ca	
10	10	Cadman	18665612701	orci.adipiscing.non@semperNam.ca	
11	11	Melyssa	5967736	vel@vulputateposuerevulputate.net	
12	12	Tanner	17397767897	arcu.Aliquam.ultrices@sociis.com	
13	13	Trevor	5121955	Nunc.quis.arcu@egestasa.org	
14	14	Allen	7332795	felis.Donec@necleo.org	
15	15	Wanda	3596973	Nam.nulla.magna@ln.org	
16	16	Alden	3418522	odio@morbitristiquesenectus.ca	
17	17	Omar	7201543	Phasellus.vitae.mauris@sollicitudin.ne	
18	18	Owen	11673357541	sociis@erat.com	
19	19	Laura	19746232057	mollis@ornare.ca	

Table v +

	1 ² ₃ ID	△B NOMBRE	∆ ^B c PERIODO
1	1	WALMART	202502
2	2	MICROSOFT	202502
3	3	APPLE	202502
4	4	TOYOTA	202502
5	5	AMAZON	202502
6	6	GOOGLE	202502
7	7	CANACIBIC	202502


Para hacer consultas sobre sql sobre los datos de un dataframe es necesario crear vistas temporales a partir de dichos dataframes.

df_personas.createOrReplaceTempView("tb_personas")
df_empresas.createOrReplaceTempView("tb_empresas")

Luego de la ejecución de la consulta se pueden almacenar en otro dataframe de la siguiente forma:

sql= """ SELECT p.periodo,e.empresa_name as nombre_empresa, p.salario,p.edad FROM tb_personas p inner join tb_empresas e on e.ID = p.ID_EMPRESA and e.periodo=p.periodo order by P.ID_EMPRESA"""

df_result_1 = spark.sql(sql)



	A ^B _C periodo	₄ ^B c nombre_empresa	1.2 salario	1 ² 3 edad
6	202502	WALMART	8818	24
7	202502	WALMART	5570	26
8	202502	MICROSOFT	9298	34
9	202502	MICROSOFT	16289	59
10	202502	MICROSOFT	3377	26
11	202502	MICROSOFT	7449	22
12	202502	MICROSOFT	6483	39
13	202502	MICROSOFT	22038	42
14	202502	MICROSOFT	21452	61
15	202502	MICROSOFT	10825	27
16	202502	MICROSOFT	22953	46
17	202502	MICROSOFT	15116	38

• 🗇 df_result_final: pyspark.sql.dataframe.DataFrame = [periodo: string, nombre_empresa: string ... 3 more fields]

Table v +

	∆ ^B _C periodo	△B _C nombre_empresa	1.2 sum_salario	1.2 avg_salario	1.2 avg_edad
1	202502	AMAZON	136609	9757.785714285714	41.2142857142857
2	202502	SONY	82012	9112.44444444445	40.888888888888
3	202502	TOYOTA	155503	19437.875	38.875
4	202502	MICROSOFT	156377	11169.785714285714	39.7857142857142
5	202502	НР	73319	8146.55555555556	39.888888888888
6	202502	WALMART	79304	11329.142857142857	35.8571428571428
7	202502	IBM	91678	15279.66666666666	37.666666666666
8	202502	SAMSUNG	106710	11856.66666666666	34.555555555556
9	202502	GOOGLE	135243	10403.307692307691	50
10	202502	APPLE	151700	13790.90909090909	39.63636363636363

<u>↓</u> 10 rows | 4.19s runtime

09:28 PM (2s)

df = spark.read.format("delta").load(path_gold)
display(df)

▶ (2) Spark Jobs

▼ 🖃 df: pyspark.sql.dataframe.DataFrame

Schema Details History

periodo: string nombre_empresa: string sum_salario: double avg_salario: double avg_edad: double

Table v +

	∆ ^B _C periodo	Δ ^B C nombre_empresa	1.2 sum_salario	1.2 avg_salario	1.2 avg_edad
1	202502	AMAZON	136609	9757.785714285714	41.2142857142857
2	202502	SONY	82012	9112.44444444445	40.888888888888
3	202502	TOYOTA	155503	19437.875	38.875
4	202502	MICROSOFT	156377	11169.785714285714	39.7857142857142
5	202502	HP	73319	8146.55555555556	39.888888888888
6	202502	WALMART	79304	11329.142857142857	35.8571428571428
7	202502	IBM	91678	15279.66666666666	37.6666666666666
8	202502	SAMSUNG	106710	11856.66666666666	34.555555555556
9	202502	GOOGLE	135243	10403.307692307691	50
10	202502	APPLE	151700	13790.90909090909	39.63636363636363


± 10 rows | 1.77s runtime

CATALOGO DE DATOS – METADA REFERENCIA A ARCHIVOS ALMACENADOS (INTERNA O EXTERNAMENTE)


Brinda posibilidad de ejecutar consultas sql.

En el caso del community solo podemos alcanzar el nivel de bases de datos (schemas) y tablas (también vistas).






En la carpeta producción->ddl creamos la carpeta schemas. Dentro creamos un notebook de tipo de lenguaje SQL. Usamos sentencias para listar los catálogos, las bases de datos y las tablas dentro de las bases de datos existentes.





Creamos los esquemas para nuestras tres capas: bronze, silver, gold



En la carpeta ddl de cada tabla creamos el esquema de la tabla. Empezando por la capa bronze.

Las tablas creadas son de tipo external y delta. Por ser de tipo delta basta con indicar el location para que se considere como external aunque no se asigne la palabra external en la creación de la tabla.





```
CREATE EXTERNAL TABLE bronze.transacciones(

ID_PERSONA STRING,
ID_EMPRESA STRING,
MONTO STRING,
FECHA STRING
)
USING DELTA
LOCATION 'gs://dmc_dde_barb/produccion/dmc/bronze/
transacciones'

(3) Spark Jobs

OK
```

▶ ✓ 10:03 PM (2s)

select * from bronze.transacciones;

(2) Spark Jobs


Table • +

	ABC ID_PERSONA	ABC ID_EMPRESA	A ^B _C MONTO	A ^B c
23	83	5	2079	20
24	48	4	2543	20
25	15	6	1434	20
26	89	4	780	20
27	4	2	863	20
28	22	4	2058	20
29	10	3	2027	20
30	48	1	3833	20
31	66	1	3847	20
32	87	2	3581	20
33	43	2	3310	20
34	71	10	4028	20
35	74	7	3360	20
36	57	7	3331	20
-				

Q70

Iniciamos con la creación de la definición de las tablas para la capa silver.

```
✓ Just now (1s)
    CREATE EXTERNAL TABLE IF NOT EXISTS silver.personas(
        ID INT,
        ID_EMPRESA INT,
        NOMBRE STRING,
        EDAD INT,
        TELEFONO STRING,
        CORREO STRING,
        SALARIO DOUBLE,
        FECHA_INGRESO DATE,
        ANIO INT,
        MES INT,
        DIA INT,
        SEGMENTO STRING,
        PERIODO STRING
    USING DELTA
    PARTITIONED BY (PERIODO)
    LOCATION 'gs://dmc_dde_barb/produccion/dmc/silver/personas';
OK
```



```
CREATE EXTERNAL TABLE IF NOT EXISTS silver.empresas(

ID INT,

NOMBRE STRING,

PERIODO STRING
)

USING DELTA

PARTITIONED BY (PERIODO)

LOCATION 'gs://dmc_dde_barb/produccion/dmc/silver/empresas';

(3) Spark Jobs

OK
```

```
► ✓ 10:51 PM (1s)

SELECT * FROM silver.empresas;

► (2) Spark Jobs
```

Table v +

	1 ² 3 ID	A ^B _C NOMBRE	A ^B _C PERIODO		
1	1	WALMART	202502		
2	2	MICROSOFT	202502		
3	3	APPLE	202502		
4	4	TOYOTA	202502		
5	5	AMAZON	202502		
6	6	GOOGLE	202502		
7	7	SAMSUNG	202502		
8	8	HP	202502		
9	9	IBM	202502		
10	10	SONY	202502		

<u>↓</u> 10 rows | 1.13s runtime

	A ^B _C PERIODO
1	202502

Table v +

```
CREATE EXTERNAL TABLE IF NOT EXISTS silver.transacciones(

ID_PERSONA INT,
ID_EMPRESA INT,
MONTO DOUBLE,
FECHA DATE,
ANIO INT,
MES INT,
DIA INT
)

USING DELTA
PARTITIONED BY (ANIO, MES, DIA)
LOCATION 'gs://dmc_dde_barb/produccion/dmc/silver/transacciones';

(3) Spark Jobs

OK
```

▶ ∨ ✓ Just now (1s)

show partitions silver.transacciones;

▶ (2) Spark Jobs

Table v +

	1 ² ₃ ANIO	1 ² 3 MES	1 ² 3 DIA
1	2018	1	21
2	2018	1	22
3	2018	1	23

± 3 rows | 0.82s runtime

```
SELECT * FROM silver.transacciones LIMIT 3;


> (1) Spark Jobs
```

Table v +

	1 ² ₃ ID_PERSONA	1 ² ₃ ID_EMPRESA	1.2 MONTO	⊟ FECHA	1 ² 3 AN
1	18	3	1383	2018-01-21	
2	30	6	2331	2018-01-21	
3	47	2	2280	2018-01-21	

Creamos una subcarpeta dentro del bucket para la capa gold

Gold→machine-learning→analisis-x-salario



Creamos el ddl de la capa gold para análisis-x-salario

```
CREATE EXTERNAL TABLE IF NOT EXISTS gold.analisis_x_salario(

periodo STRING,
    nombre_empresa STRING,
    sum_salario DOUBLE,
    avg_salario DOUBLE,
    avg_edad DOUBLE
)

USING DELTA
LOCATION 'gs://dmc_dde_barb/produccion/dmc/gold/machine-learning/analisis-x-salario';
```

